PT-02

Análise Exploratória do dataset Wine

Valentim S. A. Neto

Matrícula: 2019027210

Disciplina: Aprendizado de Máquina

Professor: Frederico Coelho

Relatório de análise exploratória

1. Dataset e variáveis

O Wine é um dataset clássico de classificação com 178 amostras, 13 variáveis numéricas positivas e três classes. Cada linha contém resultados de análises químicas de um vinho. Não há valores ausentes.

As entradas são: alcohol, malic_acid, ash, alcalinity_of_ash, magnesium, total_phenols, flavanoids, nonflavanoid_phenols, proanthocyanins, color_intensity, hue, od280/od315_of_diluted_wines e proline. A saída é target, com as classes 0, 1 e 2, associadas a class_0, class_1 e class_2.

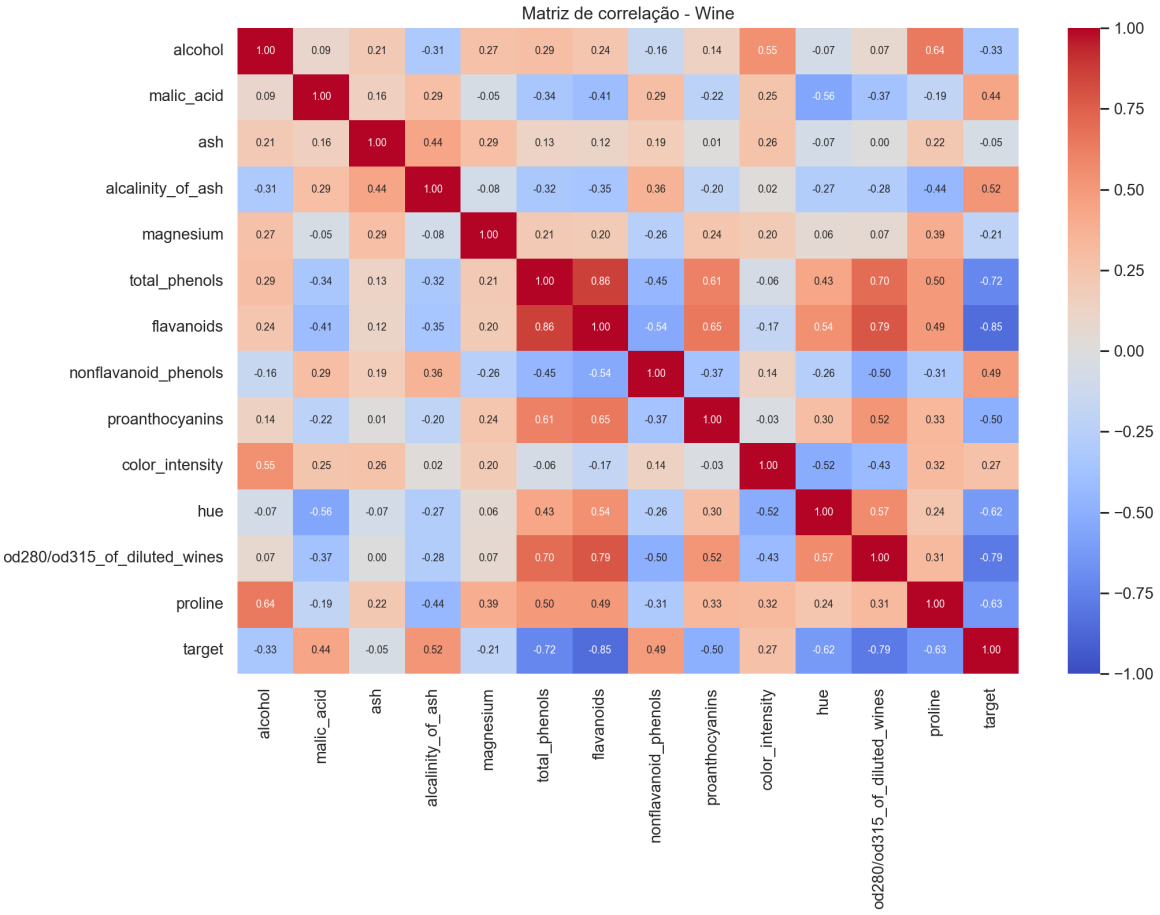
Fonte consultada: documentação oficial do scikit-learn, load_wine (https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_wine.html).

2. Resumo estatístico

Variável	Média	Desvio	Mín.	Máx.
alcohol	13.0	0.81	11.03	14.83
malic_acid	2.34	1.12	0.74	5.8
ash	2.37	0.27	1.36	3.23
alcalinity_of_ash	19.49	3.34	10.6	30.0
magnesium	99.74	14.28	70.0	162.0
total_phenols	2.3	0.63	0.98	3.88
flavanoids	2.03	1.0	0.34	5.08
nonflavanoid_phenols	0.36	0.12	0.13	0.66
proanthocyanins	1.59	0.57	0.41	3.58
color_intensity	5.06	2.32	1.28	13.0
hue	0.96	0.23	0.48	1.71
od280/od315_of_diluted_wines	2.61	0.71	1.27	4.0
proline	746.89	314.91	278.0	1680.0

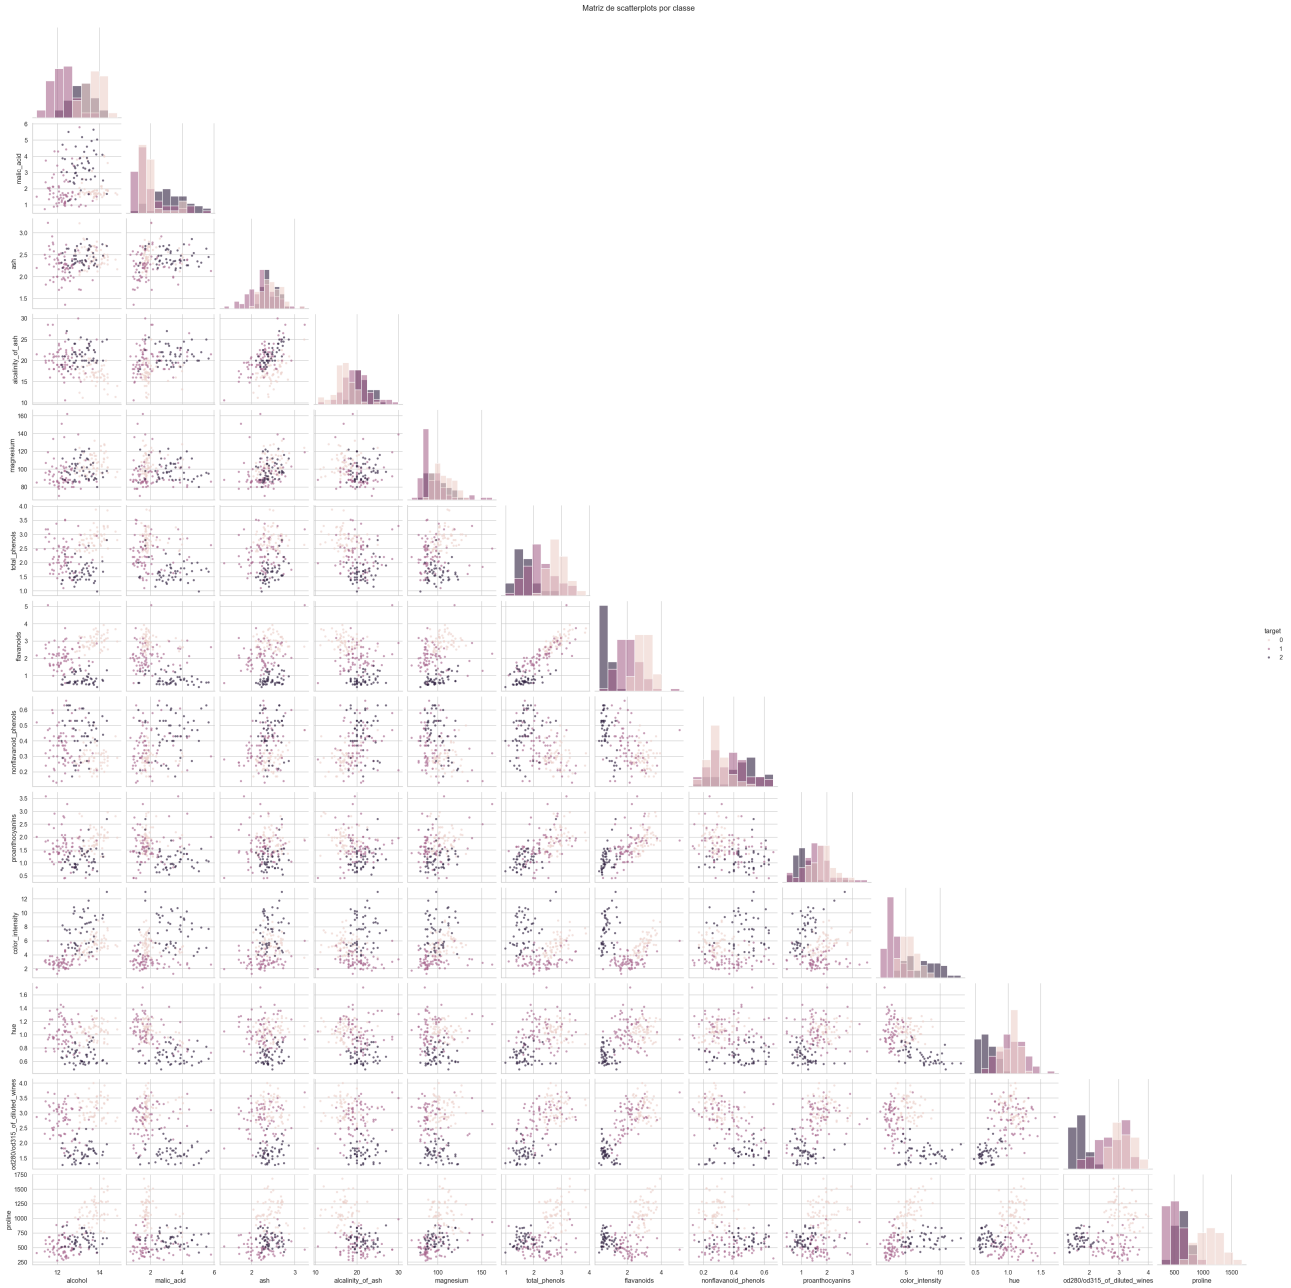
As amplitudes são muito diferentes: proline varia de 278 a 1.680, enquanto outras medidas ficam próximas de zero. Em uma etapa de modelagem, algoritmos sensíveis à escala devem receber dados padronizados.

3. Matriz de correlações



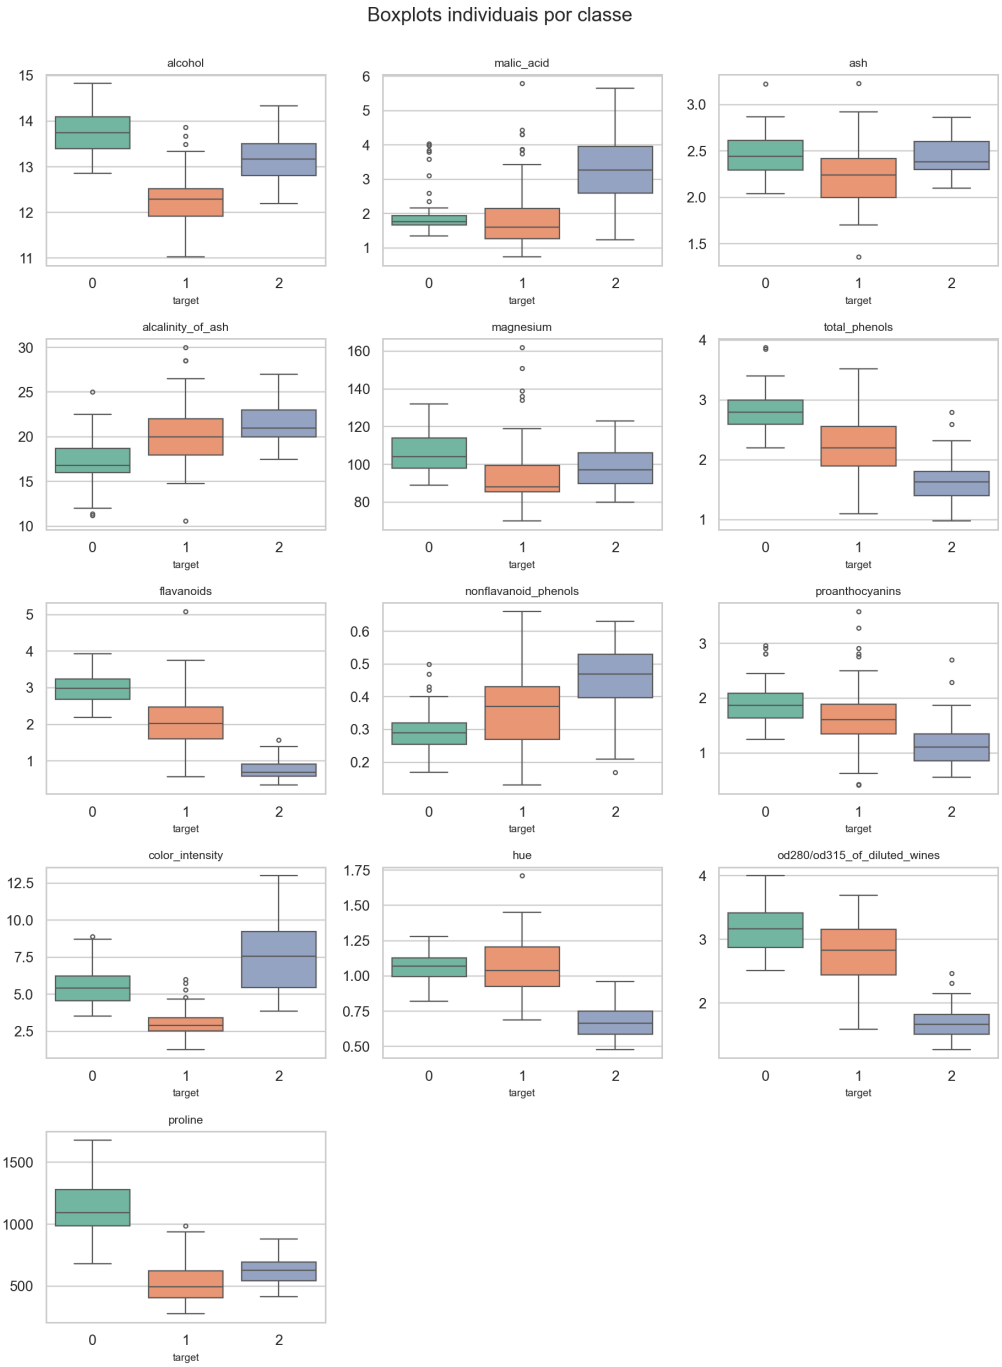
Entre as variáveis de entrada, o único par que supera |r| = 0,80 é total_phenols e flavanoids (r = 0.865). A relação forte indica informação linear parcialmente duplicada. A correlação com target deve ser interpretada com cautela, pois os números 0, 1 e 2 são códigos de classes, não uma medida contínua.

4. Scatterplots



Os scatterplots reforçam a proximidade entre total_phenols e flavanoids. Flavanoids, od280/od315_of_diluted_wines, proline, color_intensity e alcohol exibem separações úteis entre classes. Ash apresenta forte sobreposição, e magnesium também separa pouco quando observado isoladamente. Nenhuma variável separa perfeitamente as três classes.

5. Boxplots e outliers



Os boxplots foram construídos individualmente para respeitar as escalas. Pelo critério de Tukey aplicado globalmente, foram encontrados outliers em: malic_acid (3), ash (3), alcalinity_of_ash (4), magnesium (4), proanthocyanins (2), color_intensity (4), hue (1). Esses pontos não foram removidos: um outlier visual pode ser uma observação válida e a decisão de exclusão exigiria investigação adicional.

Ash possui distribuições bastante sobrepostas nas três classes. Magnesium também apresenta grande sobreposição. Em contraste, flavanoids, od280/od315_of_diluted_wines, proline, color_intensity e alcohol exibem deslocamentos claros de mediana ou intervalo entre pelo menos duas classes.

6. Conclusões e respostas

1. Quais variáveis têm alta correlação? Total_phenols e flavanoids, com r = 0.865. A proximidade de 1 e o padrão quase linear no scatterplot mostram que variam juntas; por isso, parte de sua informação é redundante.

2. Quais parecem não ajudar a distinguir as classes? Ash é a principal candidata, pois suas caixas e pontos se sobrepõem amplamente. Magnesium também parece pouco discriminativa isoladamente. Isso não prova irrelevância multivariada: uma variável fraca sozinha ainda pode ajudar em interação com outras.

3. Quais variáveis considerar remover? Eu testaria remover total_phenols e manter flavanoids, que preserva o principal sinal do par redundante. Também avaliaria retirar ash. Magnesium seria uma candidata secundária, apenas se testes de validação mostrarem que sua retirada não reduz o desempenho.

A seleção proposta é uma hipótese baseada na AED. Para uma decisão definitiva, deve-se comparar por validação cruzada o modelo completo com versões reduzidas. Essa etapa evita transformar correlação ou sobreposição visual em uma conclusão causal ou automática.

Referência

SCIKIT-LEARN DEVELOPERS. load_wine: Load and return the wine dataset (classification). Documentação oficial. Disponível em: https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_wine.html. Acesso em: 27 ago. 2026.