UNIVERSIDADE FEDERAL DE MINAS GERAIS
DEPARTAMENTO DE ENGENHARIA ELETRÔNICA
PROF. FREDERICO GUALBERTO FERREIRA COELHO



ANÁLISE E EXPLORAÇÃO DOS DADOS

Valentim Soares de Andrade Neto (2019027210)

Disciplina: EEE049 - Aprendizado de Máquina

28 de agosto de 2026

1 Introdução

A Análise Exploratória de Dados (AED) é uma etapa importante no desenvolvimento de modelos de aprendizado de máquina, pois permite compreender as características do conjunto de dados antes da modelagem. Por meio de medidas estatísticas e representações gráficas, é possível identificar padrões, valores atípicos, variáveis pouco relevantes e possíveis redundâncias.

Neste trabalho, será analisado o dataset *Wine*, disponibilizado pela biblioteca `scikit-learn`. A análise utilizará estatísticas descritivas, matriz de correlações, scatterplots e boxplots para investigar as relações entre as variáveis e sua capacidade de distinguir as classes de vinho.

2 Objetivos e dados

O objetivo deste trabalho é realizar uma análise exploratória do dataset *Wine*, buscando identificar variáveis relevantes, pouco informativas ou redundantes para um problema de classificação.

O conjunto de dados possui 178 amostras, 13 variáveis de entrada numéricas e uma variável de saída denominada `target`. Essa variável representa três classes distintas de vinho. Durante a análise, serão avaliados o resumo estatístico, as correlações, a distribuição das variáveis entre as classes e a presença de valores atípicos.

3 Descrição estatística dos dados

Inicialmente, foi utilizado o método `describe()` para obter uma visão geral das variáveis de entrada. O dataset não apresenta valores ausentes, e todas as 178 amostras possuem valores para as 13 características.

A análise revelou diferenças significativas entre as escalas das variáveis. Por exemplo, `proline` apresenta valores entre 278 e 1680, enquanto variáveis como `nonflavanoid_phenols` possuem valores inferiores a 1. Essa diferença de escala deve ser considerada durante a construção de modelos sensíveis à magnitude das variáveis, podendo ser necessária uma etapa de padronização.

Variável	Média	Desvio	Mín.	Máx.
alcohol	13.0	0.81	11.03	14.83
malic_acid	2.34	1.12	0.74	5.8
ash	2.37	0.27	1.36	3.23
alcalinity_of_ash	19.49	3.34	10.6	30.0
magnesium	99.74	14.28	70.0	162.0
total_phenols	2.3	0.63	0.98	3.88
flavanoids	2.03	1.0	0.34	5.08
nonflavanoid_phenols	0.36	0.12	0.13	0.66
proanthocyanins	1.59	0.57	0.41	3.58
color_intensity	5.06	2.32	1.28	13.0
hue	0.96	0.23	0.48	1.71
od280/od315_of_diluted_wines	2.61	0.71	1.27	4.0
proline	746.89	314.91	278.0	1680.0

Figura 1: Resumo estatístico das variáveis de entrada do dataset Wine.

4 Análise de correlação

A matriz de correlações foi utilizada para identificar relações lineares entre as variáveis. Foram consideradas fortes as correlações cujo valor absoluto fosse igual ou superior a 0,80.

Conforme apresentado na Figura 2, o único par de variáveis de entrada que ultrapassou esse limite foi `total_phenols` e `flavanoids`, com correlação de aproximadamente 0,865. Esse resultado indica que as duas características carregam informações semelhantes e podem ser parcialmente redundantes.

A correlação entre as variáveis de entrada e a variável `target` deve ser interpretada com cautela, pois os valores 0, 1 e 2 representam códigos de classes, e não uma medida numérica contínua.

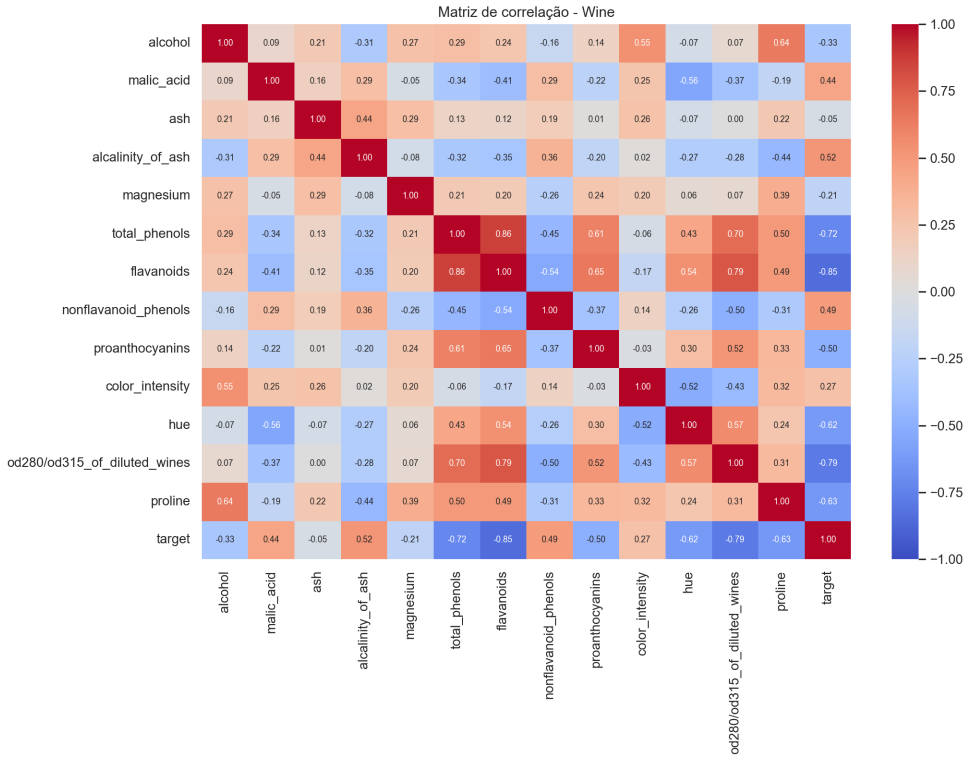


Figura 2: Matriz de correlações do dataset Wine.

5 Análise dos scatterplots

A matriz de scatterplots permite observar as relações entre pares de variáveis e a distribuição das três classes. As cores utilizadas nos gráficos representam os diferentes valores da variável `target`.

A Figura 3 reforça a forte relação entre `total_phenols` e `flavanoids`. Variáveis como `flavanoids`, `proline`, `color_intensity`, `alcohol` e `od280/od315_of_diluted_wines` apresentam separações visuais relevantes entre pelo menos algumas das classes.

Por outro lado, a variável `ash` apresenta grande sobreposição entre as classes. A variável `magnesium` também possui separação limitada quando analisada isoladamente. Entretanto, nenhuma das características é capaz de separar perfeitamente as três classes por conta própria.

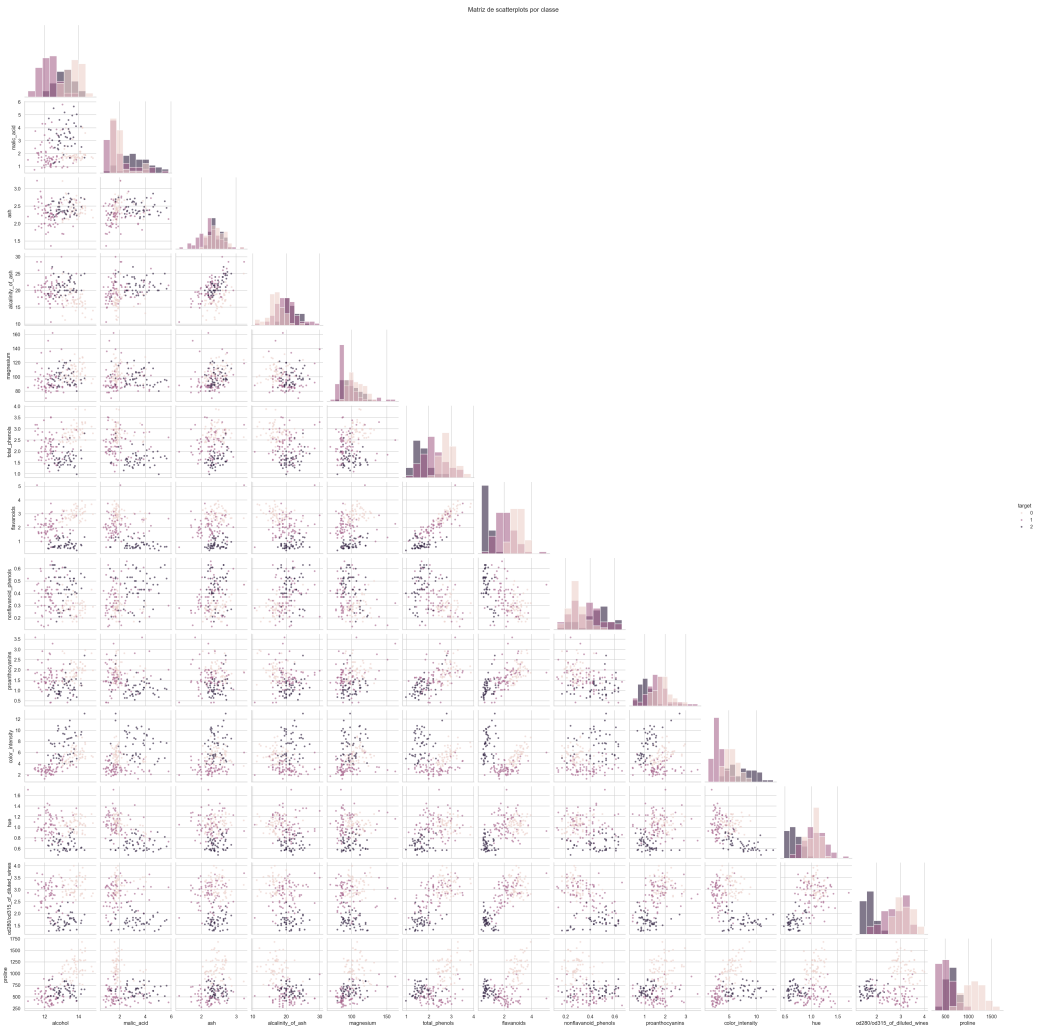


Figura 3: Matriz de scatterplots das variáveis, separadas pela classe de vinho.

6 Análise dos boxplots

Os boxplots foram construídos individualmente para cada variável, evitando que as diferenças de escala prejudicassem a visualização. Esses gráficos permitem comparar medianas, dispersões e possíveis valores atípicos entre as classes.

As variáveis `flavanoids`, `proline`, `color_intensity`, `alcohol` e `od280/od315_of_diluted_wines` apresentam diferenças perceptíveis entre

as distribuições das classes. Em contraste, `ash` possui distribuições bastante sobrepostas, enquanto `magnesium` apresenta uma separação menos evidente.

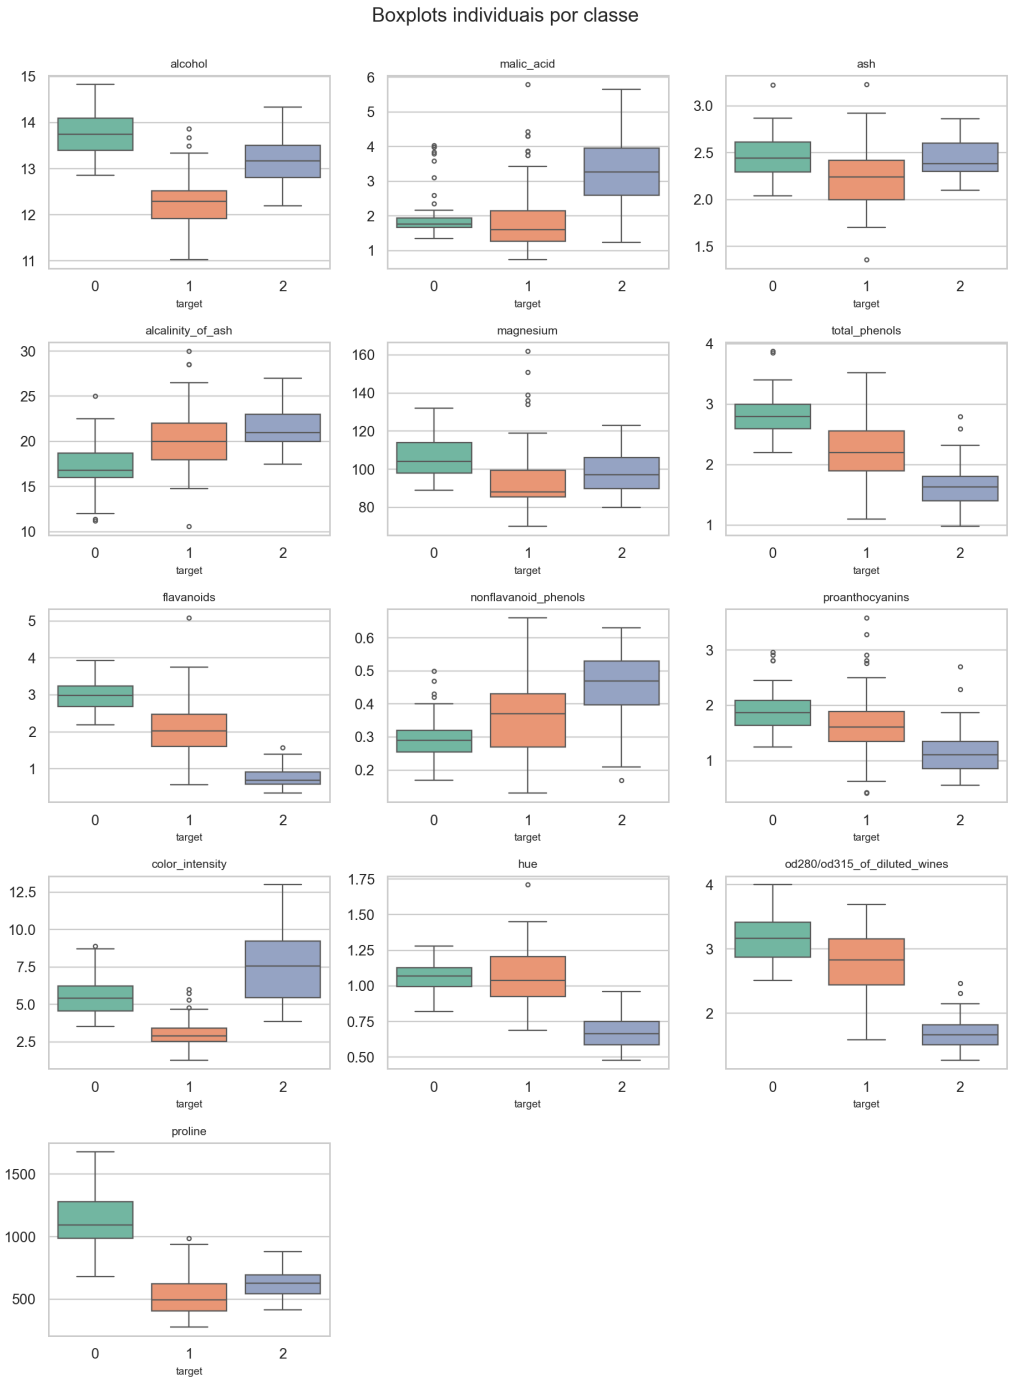


Figura 4: Boxplots individuais das variáveis de entrada em relação às classes.

6.1 Identificação de outliers

Utilizando o critério de Tukey, baseado em 1,5 vezes o intervalo interquartil, foram identificados possíveis outliers nas variáveis `malic_acid`, `ash`, `alcalinity_of_ash`, `magnesium`, `proanthocyanins`, `color_intensity` e `hue`.

Essas observações não foram removidas, pois um valor fora dos limites do boxplot não representa necessariamente um erro. Uma decisão de remoção exigiria uma investigação adicional sobre a origem e a validade de cada observação.

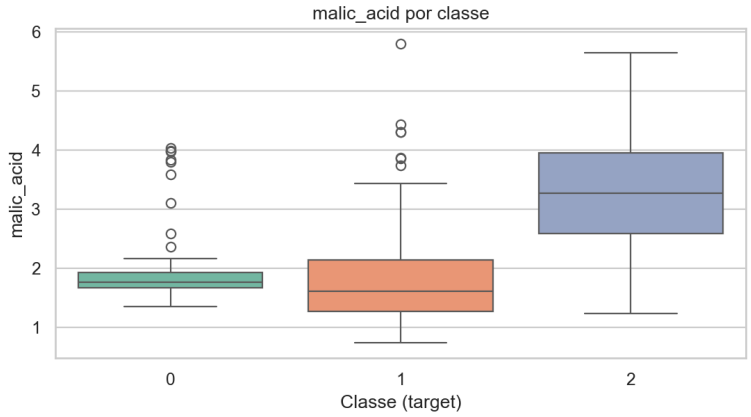


Figura 5: Boxplot da variável `malic_acid` em relação às classes.

7 Identificação de variáveis redundantes e irrelevantes

A principal redundância encontrada envolve as variáveis `total_phenols` e `flavanoids`. Além da correlação de aproximadamente 0,865, os scatterplots indicam que elas apresentam um comportamento linear semelhante. Dessa forma, seria possível testar a remoção de `total_phenols`, mantendo `flavanoids` para preservar a principal informação do par.

A variável `ash` é a principal candidata a característica pouco relevante, devido à grande sobreposição observada entre as classes. A variável `magnesium` também pode ser avaliada como candidata secundária, embora ainda possa fornecer informações úteis quando combinada com outras características.

Essas observações representam hipóteses produzidas pela análise exploratória. A remoção definitiva das variáveis deve ser confirmada por meio da comparação

do desempenho de modelos com diferentes conjuntos de características.

8 Conclusão

A análise exploratória permitiu compreender a distribuição e as relações existentes entre as variáveis do dataset *Wine*. Foi identificada uma forte correlação entre `total_phenols` e `flavanoids`, indicando possível redundância. A variável `ash` apresentou baixa capacidade de separação visual, enquanto `magnesium` também demonstrou sobreposição considerável entre as classes.

Com base nesses resultados, recomenda-se avaliar a remoção de `total_phenols` e `ash`. A retirada de `magnesium` pode ser considerada em um experimento adicional. Entretanto, essas decisões devem ser validadas por meio do treinamento e da avaliação de modelos com o conjunto completo e com versões reduzidas das variáveis.