Regressão logística para concessão de crédito

Prática 4 | Aprendizado de Máquina
Universidade Federal de Minas Gerais
Valentim Soares de Andrade Neto | Matrícula: 2019027210
Professor: Frederico Gualberto Ferreira Coelho

1. Objetivo e metodologia

Aplicar um modelo de regressão logística já treinado para estimar a probabilidade de inadimplência, interpretar seus coeficientes e discutir o efeito do limiar de classificação. O exercício é fictício; não foram ajustados novos coeficientes nem utilizados dados externos.

Modelo fornecido:
$z = -4{,}5 + 0{,}08 \times \text{Idade} - 0{,}00003 \times \text{Renda} + 1{,}2 \times \text{Atrasos} + 0{,}9 \times \text{Divida}$
$p = 1 / (1 + \exp(-z))$

Idade é medida em anos; Renda é anual, em reais; Atrasos corresponde ao número de atrasos no último ano; Divida vale 0 para dívida baixa e 1 para dívida alta. O evento positivo (Y = 1) é a inadimplência.

2. Parte 1: probabilidades dos clientes

Cliente	Idade	Renda (R$)	Atrasos	Dívida	Logit	p (%)
A	25	40.000	0	0	-3,70	2,41
B	40	50.000	2	1	0,50	62,25
C	55	120.000	1	0	-2,50	7,59
D	30	80.000	3	1	-0,00	50,00

Para A, por exemplo, $z = -4{,}5 + 0{,}08 \times 25 - 0{,}00003 \times 40.000 = -3{,}7$, resultando em $p = 0{,}024127$, ou 2,41%. B apresenta o maior risco estimado (62,25%). Para D, $z = 0$ e a probabilidade é 50%.

A implementação usa uma sigmoide numericamente estável, baseada em logaddexp. Foram conferidos os quatro logits, as probabilidades, as classificações e o comportamento da função para valores extremos. Todas as verificações do notebook passaram.

3. Parte 2: interpretação dos coeficientes

a) Influência no aumento do risco. Por incremento de uma unidade, Atrasos tem o maior coeficiente positivo (1,2), seguido de Divida (0,9) e Idade (0,08). Um atraso adicional aumenta mais o logit que um ano adicional de idade ou a mudança de dívida baixa para alta, mantendo as outras variáveis constantes. Isso não define importância global: as variáveis têm unidades e amplitudes diferentes. Por exemplo, 15 anos acrescentam 1,2 ao logit, o mesmo que um atraso.

b) Coeficiente negativo da renda. Mantidas as demais características, maior renda reduz o logit e a probabilidade prevista. Essa associação é compatível com maior capacidade de pagamento, mas não demonstra causalidade. R$ 10.000 adicionais de renda anual reduzem o logit em 0,3.

c) Efeito de um atraso. Um atraso adicional aumenta em 1,2 o logit, isto é, o logaritmo das chances de inadimplência. Não representa aumento de 1,2 na probabilidade nem de 120 pontos percentuais: a mudança na probabilidade depende do risco inicial.

d) Razões de chances. As chances são p/(1-p). A razão de chances associada a um incremento unitário é exp(coeficiente), mantendo as demais variáveis constantes.

Variação	Coeficiente	Razão de chances
Atrasos: +1	1,2	3,3201
Dívida: baixa para alta	0,9	2,4596

Um atraso adicional multiplica as chances por aproximadamente 3,32, um aumento de 232%. Passar de dívida baixa para alta multiplica as chances por 2,46, um aumento de 146%. Esses multiplicadores se aplicam às chances, não diretamente às probabilidades.

4. Parte 3: classificações por limiar

a-b) Nesta parte são usadas as probabilidades fornecidas para E-I. A regra é prever Y = 1 quando p é maior ou igual ao limiar; caso contrário, prever Y = 0.

Cliente	Probabilidade	Limiar 0,5	Limiar 0,7
E	15%	0	0
F	42%	0	0
G	58%	1	0
H	72%	1	1
I	89%	1	1

0 = adimplente previsto; 1 = inadimplente previsto. Apenas G muda de classe entre os dois limiares.

4. Parte 3: decisão econômica (continuação)

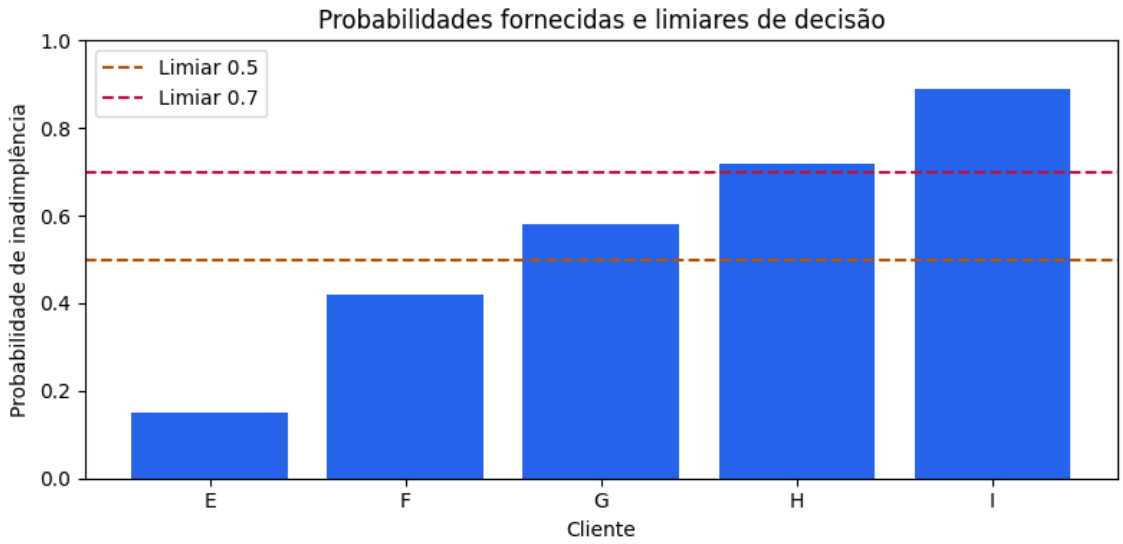


Figura 1. Probabilidades fornecidas para E-I e os dois limiares de decisão.

c) Banco. Entre 0,5 e 0,7, escolheria 0,5 sob a hipótese de que conceder crédito a um inadimplente custa mais que perder um bom cliente. O limiar menor sinaliza mais casos de risco e reduz falsos negativos, embora possa aumentar falsos positivos. Um falso negativo é um inadimplente classificado como adimplente; um falso positivo é um adimplente classificado como inadimplente.

d) Campanha de marketing. Escolheria 0,7 caso o objetivo fosse ampliar o público, houvesse análise de crédito posterior e a receita esperada justificasse maior tolerância ao risco. G passaria a ser elegível, enquanto H e I permaneceriam sinalizados. Se a oferta pré-aprovada implicasse concessão efetiva sem nova análise, manteria 0,5 sob a hipótese conservadora do item anterior.

Portanto, não existe um limiar ideal apenas por se tratar de banco ou marketing. A escolha depende da margem, valor da operação, perda esperada e custo de oportunidade. Em um modelo simplificado, com custos constantes, custo zero para acertos e probabilidades calibradas, o limiar ótimo é $\mathbf{C_{FP} / (C_{FP} + C_{FN})}$. Quanto maior o custo do falso negativo, menor o limiar indicado.

O enunciado não fornece custos nem resultados reais de inadimplência. Assim, as escolhas acima são condicionais: não é possível demonstrar qual limiar maximiza o lucro ou calcular métricas observadas de classificação.

5. Parte 4: análise crítica

Afirmação 1: probabilidade de 58% significa inadimplência certa. A afirmação confunde probabilidade com certeza. O resultado individual de G é desconhecido. Se o modelo estiver bem calibrado, entre muitos casos com previsão próxima de 58%, espera-se aproximadamente 58% de inadimplência. Uma classificação positiva não elimina essa incerteza.

Afirmação 2: pessoas mais velhas sempre têm maior risco. O efeito positivo da idade vale mantendo renda, atrasos e dívida constantes. Na comparação entre pessoas diferentes, as outras características podem compensá-lo. C, com 55 anos, tem risco previsto menor que B, com 40 anos. Além disso, o coeficiente não comprova causalidade nem garante validade fora da população estudada.

Afirmação 3: elevar o limiar para 0,9 melhora o modelo. Alterar o limiar muda as decisões, não os coeficientes nem as probabilidades. O conjunto de positivos previstos diminui: falsos positivos não aumentam, falsos negativos não diminuem e a revocação não aumenta, quando há positivos reais. A precisão pode aumentar, mas isso não é garantido em uma amostra finita.

Com limiar 0,9, todos os clientes E-I são classificados como adimplentes. Não há falsos positivos nesse grupo, mas qualquer inadimplente real seria falso negativo. A precisão TP/(TP+FP) fica indefinida porque não há previsões positivas. A revocação TP/(TP+FN) é zero se houver inadimplentes reais e indefinida se não houver. Sem os rótulos reais, não se podem determinar TP, FP, FN e TN.

6. Bônus: inclinação e sensibilidade

1) Curva mais inclinada. O modelo $z = -1{,}2 + 5X$ tem transição mais íngreme que $z = -1{,}2 + 0{,}5X$. A derivada é $dp/dX = b \times p(1-p)$, com máximo $b/4$: 1,25 para $b = 5$ e 0,125 para $b = 0{,}5$. Os centros das transições são $X = 0{,}24$ e $X = 2{,}4$, respectivamente.

2) Sensibilidade. O coeficiente 5 produz maior sensibilidade perto de sua região de transição, mas não necessariamente em todo X. Na saturação, perto de $p = 0$ ou $p = 1$, a derivada se aproxima de zero; nesse caso, o modelo com coeficiente 0,5 pode ser mais sensível no mesmo valor de X.

3) Coeficientes excessivamente grandes. Podem amplificar ruído perto da fronteira, gerar previsões extremas e indicar sobreajuste ou separação completa/quase completa. A escala da variável precisa ser considerada. Padronização, regularização e validação ajudam a investigar esses casos. Uma implementação ingênua da exponencial também pode apresentar overflow.

6. Bônus: comparação gráfica (continuação)

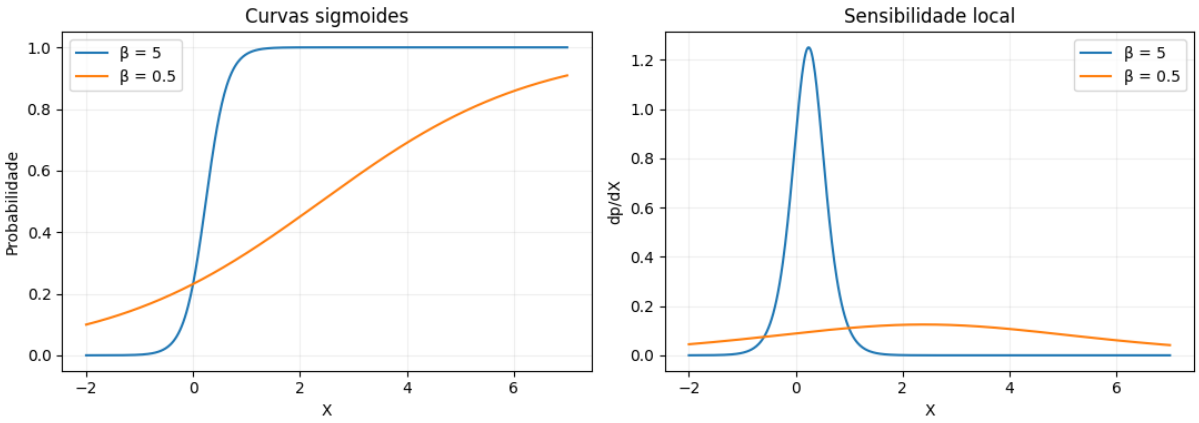


Figura 2. Curvas sigmoides e derivadas para os dois coeficientes do bônus.

7. Conclusão

A aplicação do modelo resultou em probabilidades de 2,41%, 62,25%, 7,59% e 50% para A, B, C e D, respectivamente. Atrasos apresenta o maior efeito positivo por unidade sobre o logit, mas a comparação de importância exige considerar as escalas das variáveis. Razões de chances devem ser diferenciadas de mudanças na probabilidade.

A comparação entre os limiares 0,5 e 0,7 alterou apenas a decisão sobre G. Um limiar maior não implica um modelo melhor: a escolha deve considerar os custos dos erros e os objetivos da aplicação. Como não existem rótulos reais no exercício, as conclusões se limitam às previsões e às propriedades matemáticas do modelo, sem alegar desempenho empírico.

8. Fontes e reprodução

Enunciado: *Exercicio_Regressao_Logistica.pdf*, disponível na pasta da prática 4.
Implementação e verificações: *regressao_logistica.ipynb*.
Geração do notebook: *build_pt04.py*.
Geração deste relatório: *build_relatorio.py*.

Os gráficos foram extraídos das saídas do notebook executado. As probabilidades da Parte 1 foram recalculadas a partir dos coeficientes fornecidos. Para reproduzir, instale as dependências de requirements.txt, execute python build_pt04.py e, depois, python build_relatorio.py.