# Análise discriminante
# LDA, QDA e curvas ROC

**Prática 5 | Aprendizado de Máquina**
Valentim Soares de Andrade Neto | Matrícula: 2019027210

## 1. Geração dos dados e protocolo

Foram geradas 900 observações bidimensionais com semente 42. A classe 1 (azul, rótulo 0) contém 300 amostras de uma normal centrada em (0, 0), com covariância [[1; 0,8], [0,8; 1]]. A classe 2 (vermelha, rótulo 1) reúne dois componentes de 300 amostras: média (-2; -2), covariância [[1; -0,6], [-0,6; 1]], e média (-2; 1,5), covariância [[1; 0,6], [0,6; 1]].

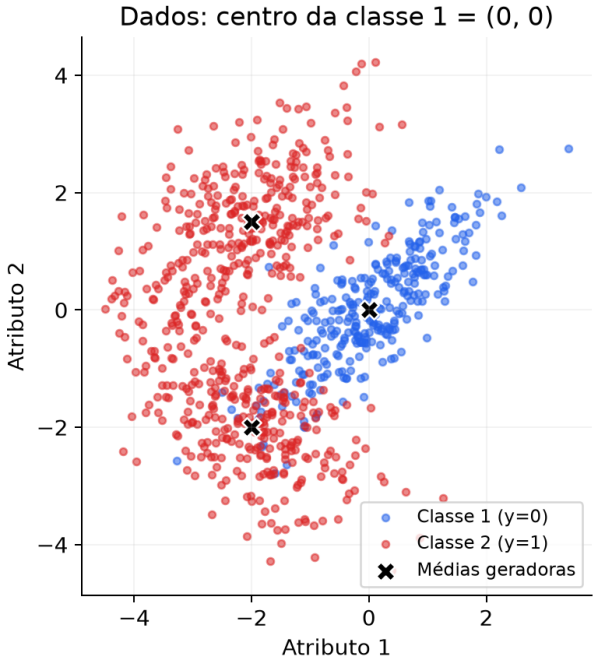



Figura 1. Dados originais e médias geradoras. A classe 2 é uma mistura de duas gaussianas. Há sobreposição, apesar do título “linearmente separáveis” presente no exemplo do enunciado.

| Grupo | Total | Treino | Teste |
|---|---|---|---|
| Classe 1 (y=0) | 300 | 217 | 83 |
| Classe 2 (y=1) | 600 | 413 | 187 |

Foi usada a divisão do enunciado: 70% para treino e 30% para teste, semente 42 e sem estratificação. LDA e QDA foram ajustados somente no treino, usando o mesmo teste. As probabilidades a priori foram estimadas no treino. A classe positiva da ROC é a classe 2 (rótulo 1).

## 2. Cenário original: fronteiras e acurácia

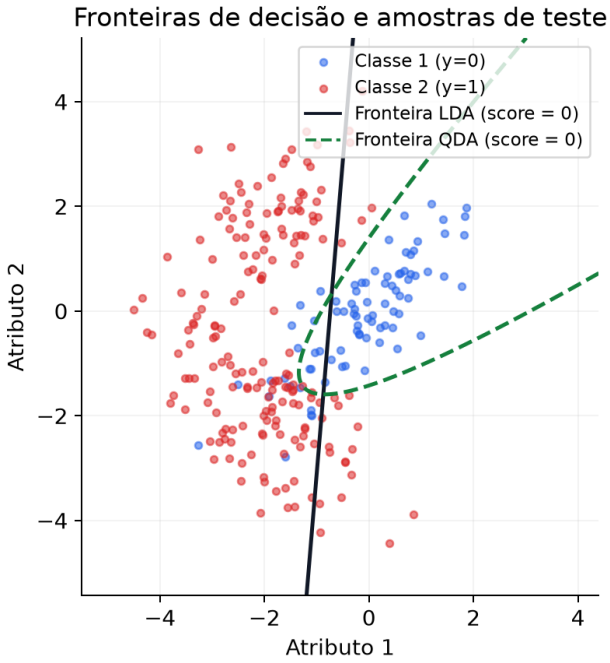



Figura 2. Fronteiras no limiar discriminante zero, sobre as 270 amostras de teste. A reta representa LDA; o contorno verde tracejado representa QDA.

| Modelo | Acurácia | AUC manual | TP | FP | TN | FN |
|---|---|---|---|---|---|---|
| LDA | 84,44% | 0,9132 | 165 | 20 | 63 | 22 |
| QDA | 94,07% | 0,9727 | 187 | 16 | 67 | 0 |

TP e TN são acertos das classes positiva e negativa; FP são amostras da classe 1 classificadas como classe 2; FN são amostras da classe 2 classificadas como classe 1. “Precisão” é interpretada como **acurácia**, conforme a métrica do enunciado: (TP + TN) / total. Ela difere de TP / (TP + FP).

**QDA teve o melhor desempenho:** acurácia de 94,07%, contra 84,44% do LDA, vantagem de 9,63 pontos percentuais. Foram 16 erros do QDA e 42 do LDA. O classificador que sempre escolhe a classe 2 teria acurácia de 69,26%.

A fronteira do QDA parece mais ajustada à geometria observada: permite curvatura e considera as diferentes covariâncias, acompanhando melhor a nuvem estreita e inclinada da classe 1. LDA impõe uma covariância comum e uma fronteira linear. A melhora visual é acompanhada por menor erro no teste.

Mesmo assim, QDA aproxima a classe 2 inteira por uma única gaussiana. Sua maior flexibilidade não representa exatamente os dois componentes geradores e não garante superioridade em qualquer conjunto de dados.

## 3. ROC manual e escolha entre os métodos

Para cada modelo, obtivemos o score discriminante do teste e variamos manualmente o limiar: a previsão é positiva se score for maior ou igual ao limiar. Contamos TP, FP, TN e FN e calculamos **TPR = TP / (TP + FN)** e **FPR = FP / (FP + TN)**. Não foram usadas funções prontas de ROC ou AUC.

Percorremos todos os scores distintos em ordem decrescente, precedidos por infinito positivo. Assim, incluímos (0, 0) e (1, 1) e tratamos empates juntos. A AUC foi calculada pela soma das áreas dos trapézios entre pontos consecutivos, sem escolher um limiar no conjunto de teste.

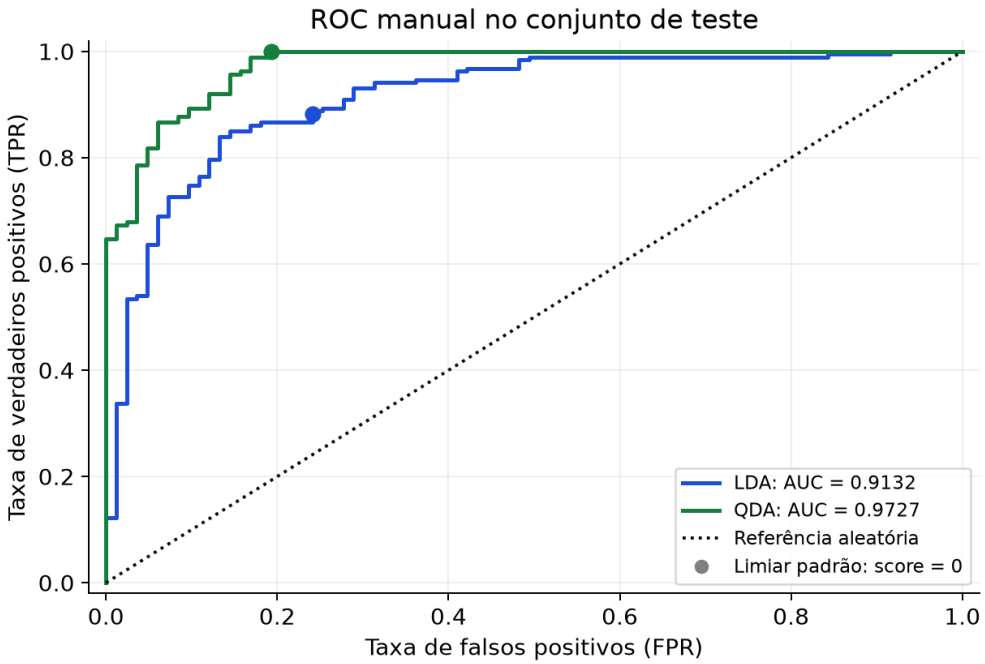



Figura 3. Curvas no mesmo gráfico. Os círculos indicam o limiar padrão zero; a diagonal é a referência de ordenação aleatória.

QDA apresenta maior área sob a curva: 0,9727, contra 0,9132. Isso indica melhor ordenação global dos positivos em relação aos negativos nesta amostra; não significa melhor desempenho em todo limiar nem mede calibração das probabilidades.

**Quando usar LDA:** covariâncias semelhantes e separação aproximadamente linear, sobretudo com poucas amostras ou muitas variáveis. Compartilhar a covariância reduz parâmetros e variância. Exemplo: classificação de sensores cujos grupos têm dispersões semelhantes.

**Quando usar QDA:** covariâncias diferentes e fronteiras curvas, com dados suficientes por classe. Exemplo: controle de qualidade com grupos de peças que apresentam correlações diferentes entre medidas. Com poucas amostras ou colinearidade, suas covariâncias podem se tornar instáveis ou singulares, exigindo regularização ou redução de dimensão.

Com d atributos e K classes, a covariância requer d(d+1)/2 parâmetros no LDA e K d(d+1)/2 no QDA. Ambos assumem uma gaussiana por classe; neste exercício, a mistura da classe 2 viola essa hipótese.

## 4. Classe 1 deslocada para (3, 3)

Somamos (3, 3) às amostras da classe 1, preservando seus ruídos e covariância, a classe 2 e os índices de treino/teste. Ambos os modelos foram treinados novamente. A única mudança é a média da classe 1.

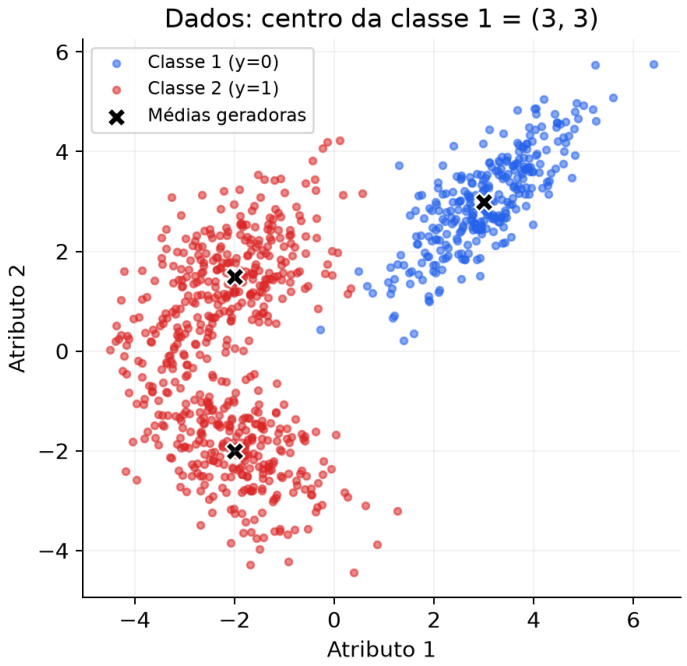



Figura 4. A classe 1 se afasta dos dois componentes da classe 2, reduzindo a sobreposição.

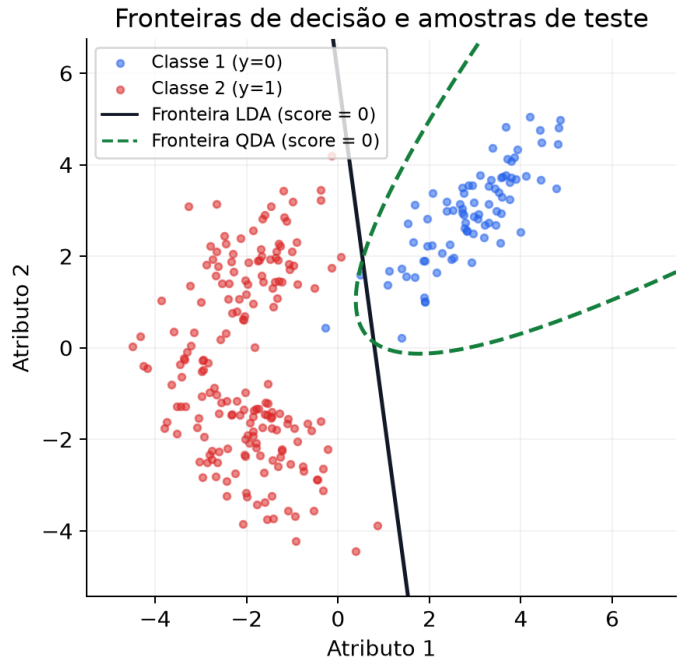



Figura 5. Fronteiras dos modelos retreinados e amostras de teste. A separação linear já se torna muito eficaz, embora as covariâncias continuem diferentes.

## 5. ROC após deslocamento e conclusões

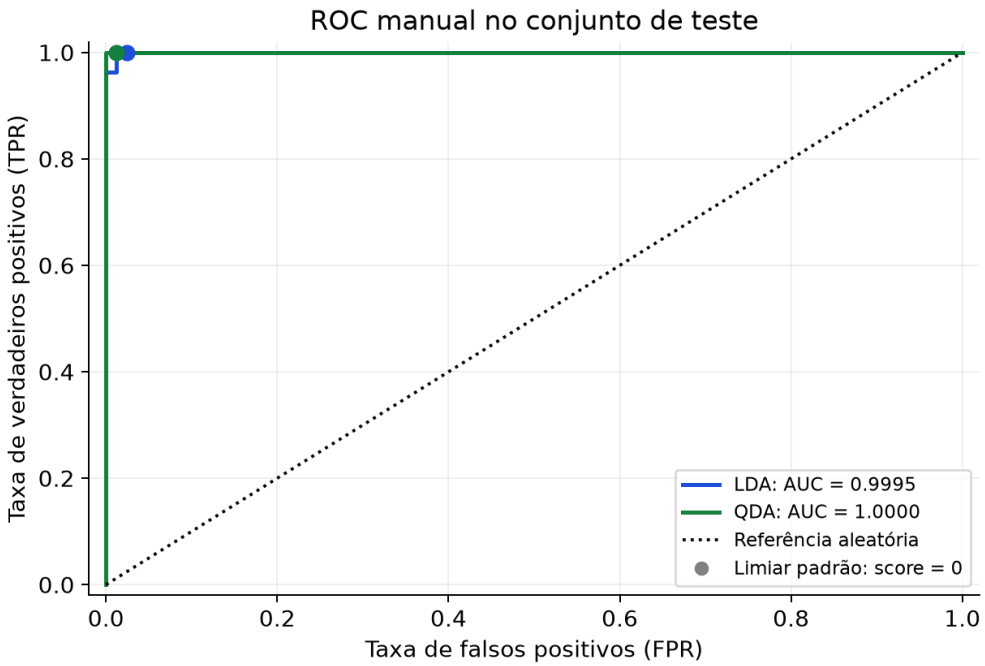



Figura 6. ROC calculada novamente pelo procedimento manual. As duas curvas se aproximam do canto superior esquerdo.

| Modelo | Acurácia | AUC manual | TP | FP | TN | FN |
|---|---|---|---|---|---|---|
| LDA | 99,26% | 0,9995 | 187 | 2 | 81 | 0 |
| QDA | 99,63% | 1,0000 | 187 | 1 | 82 | 0 |

LDA passou de 84,44% para 99,26% de acurácia; QDA passou de 94,07% para 99,63%. A vantagem do QDA caiu de 9,63 para 0,37 ponto percentual. O deslocamento, ao reduzir a sobreposição, beneficia ambos e diminui o ganho da fronteira quadrática.

As AUCs atingem 0,999549 (LDA) e 1,000000 (QDA). AUC perfeita do QDA significa que todos os positivos recebem scores maiores que os negativos nesta amostra. Não implica acurácia perfeita no limiar zero: ainda há um falso positivo. A ordenação e a decisão em um limiar fixo medem aspectos distintos.

A classe 2 permanece bimodal e as gaussianas têm suporte ilimitado. Portanto, a separação observada não prova erro populacional zero. Os resultados se limitam a uma amostra sintética e uma divisão fixa; não demonstram superioridade estatística geral. A escolha entre LDA e QDA deve considerar geometria, quantidade de dados e validação fora do treino.

**Reprodutibilidade e verificação.** O notebook executado contém todas as etapas. Foram verificados os extremos e a monotonicidade da ROC, as contagens, exemplos de scores empatados e a equivalência entre a AUC por trapézios e por comparação de pares. Os limiares e contagens foram exportados em quatro arquivos CSV.

**Fonte:** Aula 12 - Exercício Análise Discriminantes e ROC.pdf, enunciado disponibilizado na pasta da prática. Todos os gráficos e resultados deste relatório foram gerados pela resolução.