Dilema bias-variância

Prática 7 | Aprendizado de Máquina
Valentim Soares de Andrade Neto
Matrícula: 2019027210

1. Objetivo, dados e método

Investigar subajuste, ajuste adequado e sensibilidade à amostra em modelos de regressão linear com atributos polinomiais de graus 1, 2 e 10. A função geradora é $f(x) = 10 + 2x + 3x^2$, com x uniforme em [0,10] e y = f(x) + ruído gaussiano independente de média zero.

O texto do enunciado cita N(0,1), mas o código fornecido usa desvio padrão 10. Adotamos o código: cenário base com 100 dados e desvio padrão 10; ruído maior com 100 dados e desvio padrão 30; triplo de dados com 300 dados e desvio padrão 10. As variâncias do ruído são 100, 900 e 100, respectivamente.

Cenário	Dados	Treino	Teste	Desvio do ruído
Base	100	80	20	10
Ruído maior	100	80	20	30
Triplo de dados	300	240	60	10

A geração principal utiliza RandomState(42), equivalente à semente do exemplo, e a divisão utiliza 80% para treino e 20% para teste, random_state=42. Mínimos quadrados ajustam os coeficientes somente no treino, com intercepto e sem regularização. Os graus foram definidos pelo enunciado; o teste serve para avaliação.

Para estabilidade numérica, aplicamos a transformação fixa $z=(x-5)/5$ antes de gerar as potências. Essa transformação preserva os polinômios possíveis em x e não aprende informações do teste. MSE é a média dos erros quadráticos; R^2 mede a redução do erro em relação à média do conjunto avaliado. MSE é expresso em unidades de y^2; R^2 não tem unidade e pode ser negativo.

Além da divisão principal, executamos 200 repetições por cenário, com sementes 0 a 199. Elas ajudam a distinguir um resultado particular do comportamento da família de modelos, totalizando 1.800 ajustes adicionais.

2. Resultados da divisão principal

Cenário	Grau	MSE treino	MSE teste	R² treino	R² teste
Base	1	672,42	549,97	0,9232	0,9423
Base	2	81,47	63,58	0,9907	0,9933
Base	10	77,04	66,12	0,9912	0,9931
Ruído maior	1	1513,92	1186,26	0,8352	0,8723
Ruído maior	2	733,24	572,26	0,9202	0,9384
Ruído maior	10	693,35	595,08	0,9245	0,9359
Triplo de dados	1	611,25	429,24	0,9364	0,9501
Triplo de dados	2	105,23	66,64	0,9890	0,9922
Triplo de dados	10	99,02	78,69	0,9897	0,9908

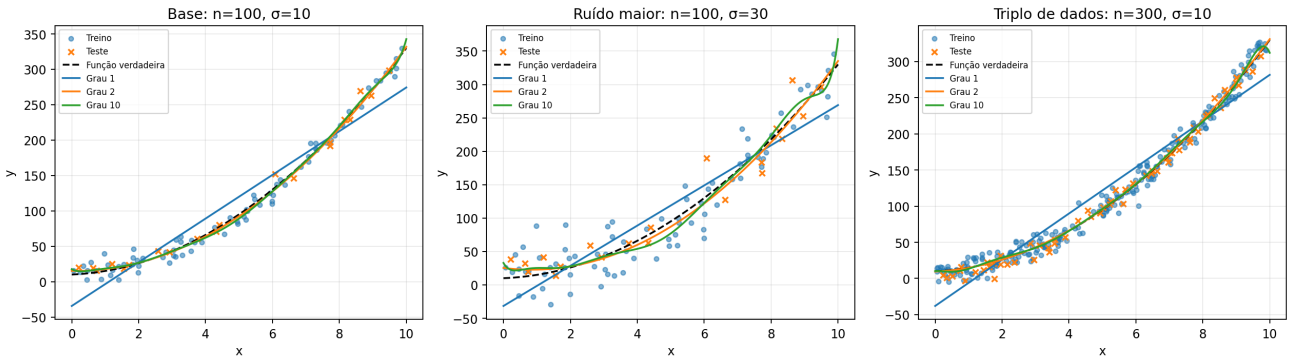


Figura 1. Dados de treino e teste, função verdadeira e curvas ajustadas. A reta não acompanha a curvatura. Os polinômios de graus 2 e 10 se aproximam da relação geradora; as diferenças locais do grau 10 refletem sua flexibilidade.

No cenário base, o grau 1 apresenta MSE de treino 672,42 e teste 549,97, maiores que os dos outros modelos. O grau 2 apresenta o menor MSE de teste, 63,58. O grau 10 reduz o erro de treino para 77,04, mas aumenta ligeiramente o de teste para 66,12. Portanto, nesta divisão o grau 10 não apresenta um teste muito ruim, embora não melhore a generalização.

O R² da reta permanece alto porque a variação total de y é grande. Isso não elimina seu subajuste: o MSE e a curva revelam que a estrutura quadrática foi omitida. Valores de MSE abaixo da variância do ruído em uma amostra de teste pequena são possíveis por flutuação amostral; não significam eliminar o erro irredutível.

3. Estabilidade em 200 repetições

Cenário	Grau	MSE treino médio	MSE teste médio	MSE teste mediano	Teste P90
Base	1	585,45	624,12	592,11	857,65
Base	2	96,44	102,43	98,06	143,46
Base	10	86,74	125,34	113,78	167,48
Ruído maior	1	1368,19	1428,99	1392,99	2063,28
Ruído maior	2	868,00	921,86	882,53	1291,13
Ruído maior	10	780,63	1128,06	1024,00	1507,28
Triplo de dados	1	602,23	605,60	612,38	720,65
Triplo de dados	2	98,42	102,22	102,16	126,42
Triplo de dados	10	94,96	106,61	104,82	130,48

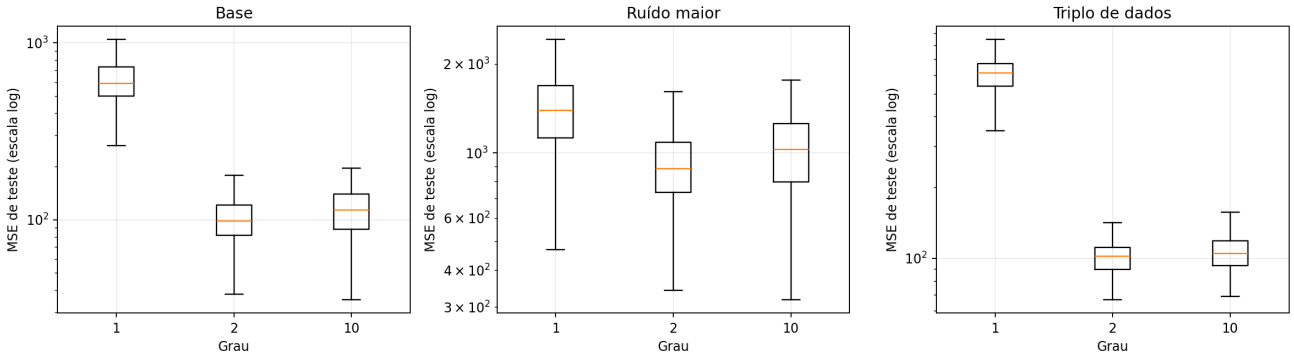


Figura 2. Distribuição do MSE de teste, em escala logarítmica. Caixas representam quartis; pontos extremos foram omitidos somente no desenho e permanecem nas médias e percentis. P90 é o valor abaixo do qual estão 90% dos resultados.

Na base, o MSE médio de teste é 624,12 para grau 1, 102,43 para grau 2 e 125,34 para grau 10. O grau 10 obtém menor erro médio de treino (86,74 versus 96,44), mas pior desempenho de teste. O grau 2 tem o melhor desempenho médio nos três cenários.

Os cenários de 100 dados compartilham x, divisão e ruído padronizado em cada semente; apenas sua amplitude muda. O cenário de 300 dados mantém o mesmo mecanismo gerador, mas não é uma ampliação aninhada da amostra anterior. As comparações de uma divisão podem refletir também a composição dos dados; as repetições reduzem a dependência de uma única realização.

4. Estimativa de bias e variância

Em uma grade fixa de 301 pontos em [0,10], calculamos a previsão média entre repetições. Bias² é a média do quadrado da diferença entre essa previsão e f(x); variância é a média da variância populacional das previsões. A decomposição empírica do erro contra f(x) em bias² + variância foi verificada numericamente. Contra uma nova resposta ruidosa, acrescentamos a variância do ruído.

Cenário	Grau	Bias²	Variância	Ruído	MSE esperado na grade
Base	1	506,75	18,63	100,00	625,39
Base	2	0,01	3,95	100,00	103,96
Base	10	0,14	32,61	100,00	132,75
Ruído maior	1	506,80	37,98	900,00	1444,78
Ruído maior	2	0,08	35,55	900,00	935,63
Ruído maior	10	1,27	293,48	900,00	1194,75
Triplo de dados	1	506,68	5,65	100,00	612,33
Triplo de dados	2	0,01	1,34	100,00	101,35
Triplo de dados	10	0,03	5,52	100,00	105,55

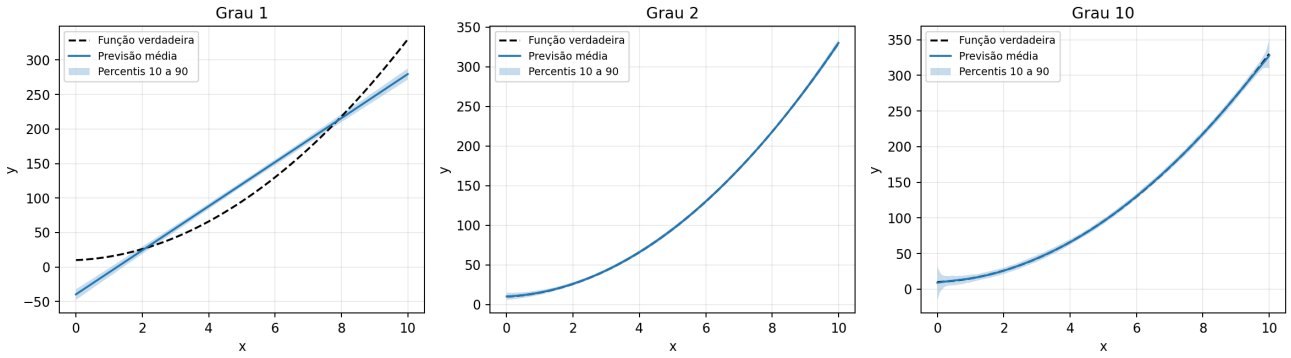


Figura 3. Previsão média e faixa entre percentis 10 e 90 no cenário base. A faixa descreve a dispersão dos modelos ajustados; não é intervalo de confiança nem intervalo preditivo para y. A sensibilidade do grau 10 aparece principalmente nas bordas.

O grau 1 mantém bias² próximo de 507: mais dados não removem a curvatura omitida. Na base, a variância é 3,95 para grau 2 e 32,61 para grau 10. Com 300 dados, cai para 1,34 e 5,52. Com ruído maior, cresce para 35,55 e 293,48, respectivamente.

Bias² e variância são estimativas finitas de 200 repetições. A grade inclui as bordas e não tem exatamente a distribuição do teste aleatório; por isso seu MSE esperado não deve coincidir com o MSE médio de teste. O pequeno bias² dos polinômios não prova bias populacional diferente de zero.

5. Respostas à discussão

1. Qual modelo teve erro alto em treino e teste (alto bias)?
O grau 1. Na base, MSE 672,42 no treino e 549,97 no teste. Ele não contém x^2, e sua estimativa de bias² é 506,75 na grade. Trata-se de subajuste.

2. Qual modelo teve baixo erro de treino e alto erro de teste (alta variância)?
O grau 10 apresenta maior risco de sobreajuste. Na divisão 42 a diferença é pequena, sem erro de teste muito alto. Nas repetições da base, o treino médio cai de 96,44 (grau 2) para 86,74, mas o teste médio sobe de 102,43 para 125,34. Sua variância estimada é cerca de 8,3 vezes a do grau 2.

3. Qual modelo tem o melhor desempenho geral?
O grau 2, com menor MSE de teste nos três cenários na divisão principal e nas médias das repetições. Ele representa a função verdadeira com poucos parâmetros: intercepto e dois coeficientes, contra onze parâmetros no grau 10.

4. Como a complexidade impacta bias e variância?
Do grau 1 para 2, o bias cai fortemente porque a curvatura passa a ser representável. Do grau 2 para 10, a flexibilidade adicional pouco acrescenta à estrutura verdadeira e aumenta a variância. O erro de treino diminui, mas o erro de teste pode aumentar. Essa tendência depende da amostra e não é uma regra determinística para toda divisão.

5. Por que o grau 10 pode ter teste ruim mesmo com treino bom?
Termos adicionais capturam parte do ruído do treino. Quando os dados mudam, os coeficientes e as curvas variam mais, especialmente nas bordas. O treino bom mede adaptação àquela amostra, sem garantir generalização. A premissa de teste ruim não ocorreu de forma acentuada na divisão 42; as repetições mostram a maior sensibilidade.

6. Aumentar o ruído altera os resultados? Por quê?
Sim. De desvio 10 para 30, a variância do ruído cresce nove vezes. Na divisão principal, MSE de teste do grau 2 sobe de 63,58 para 572,26 e do grau 10 de 66,12 para 595,08, também nove vezes: nesses modelos a função verdadeira pertence ao espaço ajustado, e os mesmos resíduos padronizados foram usados. O erro irredutível e a instabilidade aumentam; o grau 1 mantém também seu erro de especificação.

7. O que ocorre ao triplicar os dados?
A variância dos estimadores tende a diminuir. O MSE médio de teste do grau 10 cai de 125,34 para 106,61; o do grau 2 fica próximo ao piso de ruído (102,43 para 102,22). O grau 1 continua com alto bias. Na divisão principal, o MSE de teste dos graus 2 e 10 aumenta ligeiramente: mais dados não garantem melhora em cada realização, e o novo conjunto de teste contém outros ruídos.

Reprodução e limites

Notebook executado, figuras e tabelas CSV acompanham o relatório. Verificações: valores finitos, 1.800 ajustes adicionais, MSE de treino não crescente entre graus e identidade da decomposição. Simulação unidimensional, 200 repetições e domínio [0,10]; não avalia extrapolação. Versões: Python 3.12.14, NumPy 2.4.0, pandas 2.2.3, scikit-learn 1.6.1.